

Campus: São José dos Campos/ICT		
Curso(s): Bacharelado em Ciência e Tecnologia		
Unidade Curricular (UC): Aprendizado de Máquina e Reconhecimento de Padrões		
Unidade Curricular (UC): <i>Pattern Recognition and Machine Learning</i>		
Código da UC: 4413		
Docente Responsável/Departamento: Prof. Dr. Rodrigo Colnago Contreras/ Departamento de Ciência e Tecnologia		Contato (e-mail): rodrigo.contreras@unesp.br
Docente (s) Colaborador/a (es/as)/ Departamento(s):		Contato (e-mail): [opcional]
Ano letivo: 2025/15	Termo: 1	Turno: Integral
Nome do Grupo/Módulo/Eixo da UC: (se houver)		Idioma predominante em que a UC será oferecida: (X) Português () English () Español () Français () Libras () Outro:
UC: (X) Fixa () Eletiva () Optativa	Oferecida como: (X) Disciplina () Módulo () Estágio () Outro:	Oferta da UC: (X) Semestral () Anual
Ambiente Virtual de Aprendizagem: () Moodle () Classroom () Não se aplica (X) Outro: Discord		
Pré-Requisito (s) - Indicar Código e Nome (s) da (s) UC: Probabilidade e Estatística; Lógica de Programação		
Carga horária total (em horas): 72		
Carga horária teórica: 48	Carga horária prática: 24	Carga horária de extensão (se houver):
Se houver atividades de extensão, indicar código e nome do projeto ou programa vinculado na Pró-Reitoria de Extensão e Cultura (ProEC):		
Ementa: Introdução ao Reconhecimento de Padrões, Distribuições de Probabilidade, Modelos Lineares para Regressão, Modelos Lineares para Classificação, Máquinas de Sparse Kernel, Modelos Gráficos, Inferência Aproximada, Variáveis Latentes Contínuos, Dados Sequenciais.		
Conteúdo programático: Introdução a Aprendizado de Máquinas e Reconhecimento de Padrões, Teoria de probabilidade, Teoria da decisão. Distribuições de Probabilidade, Variáveis binárias e multinomiais, Distribuições Gaussianas, Família das distribuições exponenciais. Modelos Lineares para Regressão, Modelos lineares de funções básicas, Regressão Bayesiano linear. Modelos Lineares para Classificação, Funções discriminantes, Modelos generativos probabilísticos, Modelos discriminativos probabilísticos. Máquinas de Sparse Kernel, Support Vector Machines (SVM), Relevance Vector Machines (RVM). Modelos Gráficos, Redes Bayesianas, Markov Random Fields (MRF), Inferência em modelos gráficos. Inferência Aproximada, Métodos Monte Carlo, Métodos Variacionais. Variáveis Latentes Contínuos, Análise dos componentes principais (PCA), PCA probabilísticos. Modelos de Dados Sequenciais.		
Objetivos: Gerais: Capacitar os alunos a compreenderem os fundamentos teóricos e práticos do reconhecimento de padrões e aprendizado de máquinas, com foco em modelos probabilísticos, inferência estatística e métodos computacionais. Desenvolver habilidades para modelar, analisar e implementar soluções baseadas em algoritmos de classificação, regressão, inferência aproximada e análise de dados sequenciais, proporcionando uma base sólida para pesquisas avançadas ou aplicações práticas na área. Específicos: Ao final desse curso, o aluno deverá ser capaz de compreender e aplicar conceitos fundamentais de reconhecimento de padrões e aprendizado de máquinas para resolver problemas complexos. Será capaz de trabalhar com distribuições de probabilidade e teoria da decisão, desenvolver modelos lineares para regressão e classificação, e implementar algoritmos discriminativos e generativos. Além disso, o aluno deverá dominar o uso de máquinas de sparse kernel, como SVMs e RVMs, e realizar inferência em modelos gráficos, utilizando métodos exatos e aproximados, como Monte Carlo e variacionais. Também será capaz de analisar dados utilizando técnicas baseadas em variáveis latentes contínuas, como PCA, e aplicar modelos adequados para dados sequenciais. Por fim, o aluno estará apto a projetar, implementar e avaliar soluções baseadas em aprendizado de máquinas, tanto para aplicações práticas quanto para pesquisa avançada.		

Metodologia de ensino: As aulas serão ministradas por meio de exposições teóricas sobre os conceitos fundamentais, complementadas por atividades práticas de laboratório focadas na experimentação envolvendo situações problema do mundo real. Além disso, metodologias ativas de ensino, como a gamificação utilizando o Discord, serão eventualmente implementadas para tornar o aprendizado mais dinâmico e engajador. Quando disponíveis, os monitores irão auxiliar no desenvolvimento das atividades práticas solicitadas, proporcionando suporte adicional aos alunos durante o curso.

Avaliação: A avaliação se dará por meio de duas provas teóricas, P1 e P2, um trabalho prático, T, e determinadas atividades realizadas em sala que, somadas, são representadas pelo montante E, totalizando a nota final, NF, contabilizada como segue:

$$NF = \min\{(P1+P2+0.1*T + E) / 2, 10\},$$

na qual, P1, P2, T e E pertencem ao intervalo [0,10].

O aluno será considerado aprovado se NF pertencer ao intervalo [6,10] e reprovado no caso contrário.

Bibliografia:

Básica:

1. Faceli, K.; Lorena, A.C.; Gama, J.; Carvalho, A.C.P.L.F. Inteligência Artificial: uma abordagem de aprendizado de máquina. LTC, 2011.
2. Alpaydin, E. Introduction to Machine Learning. MIT Press, 2009, 2nd edition. 3. Bishop, C. M. Pattern Recognition and Machine Learning. Springer, 2006.

Complementar:

1. Duda, R.; Hart, P. E., Stork, D. Pattern Classification. 2nd edition, Wiley-Interscience, 2000.
2. Hastie, T.; Tibshirani, R.; Friedman, J. The Elements of Statistical Learning (Data Mining, Inference and Prediction), 2nd edition, Springer, 2009.
3. Marsland, S. Machine Learning: An Algorithmic Perspective, Chapman and Hall/CRC, 2009.
4. Tam, P.; Steinbach, M.; Kumar, V. Introduction to Data Mining. Addison-Wesley Pub Co, 2005.
5. Witten, I. H.; Frank, E.; Hall, M. A. Data Mining: practical machine learning tools and techniques, 3rd edition, Morgan Kaufmann, 2011.
6. Mitchell, T.M. Machine learning. New York: McGraw-Hill, 1997.
7. Abu-Mostafa, Y.; Magdon-Ismail, M., Lin, H. T. Learning From Data, AMLBook, 2012.